

Problem Set 2 - Grupo 10

Laura Buitrago Niño* María Camila Ortíz† Camilo Ramírez Arias‡

14 de abril de 2025

Resumen

Este documento presenta los resultados de un ejercicio de predicción de la pobreza monetaria en Colombia, a partir de un enfoque multidimensional que estima la probabilidad de que una persona se encuentre en situación de pobreza. Se emplean variables relacionadas con salud, educación, condiciones de vida y empleo, integradas en modelos de aprendizaje supervisado como Logit, Elastic Net, Random Forest, Naive Bayes, Bagging, Boosting y XGBoost. Usando datos de la Gran Encuesta Integrada de Hogares (GEIH), proporcionados a través de la competencia en Kaggle (Naus, 2025), se construyen características sociodemográficas y estructurales a nivel de hogar, con el fin de clasificar la clase “Pobre”. El modelo con mejor desempeño predictivo, medido por el F1 Score en la competencia, fue un *XGBoost* que alcanzó un F1 de 0.6962. Este resultado se obtuvo tras la implementación de técnicas de sobremuestreo (SMOTE), validación cruzada y una cuidadosa selección de hiperparámetros, lo que permitió capturar no linealidades, manejar el desbalance de clases y generalizar adecuadamente a nuevos datos. Además, el modelo final destacó por una adecuada selección de variables explicativas que recogen de forma robusta dimensiones clave del bienestar, como la afiliación a salud, la composición del hogar, el nivel educativo, las condiciones de la vivienda y la situación laboral de los miembros del hogar.

Nota: El repositorio relacionado a este documento se encuentra disponible en GitHub: https://github.com/Laura-BN/ProblemSet2_G10.

Palabras clave: pobreza, pobreza multidimensional, aprendizaje supervisado, clasificación, modelos de ensamble, XGBoost, GEIH, MESEP, Colombia.

Clasificación JEL: I32, C88, O10

*Facultad de Economía, Universidad de los Andes, Bogotá, Colombia. *Email:* la.buitragon1@uniandes.edu.co

†Facultad de Economía, Universidad de los Andes, Bogotá, Colombia. *Email:* mc.ortizal@uniandes.edu.co

‡Facultad de Economía, Universidad de los Andes, Bogotá, Colombia. *Email:* ca.ramirez10@uniandes.edu.co

1. Introducción

La medición de la pobreza ha sido ampliamente estudiada en la literatura, así como por las organizaciones multilaterales, la identificación de sus causas permite atacar la problemática de manera efectiva y eficiente dada la limitación de recursos de los países. Este documento tiene como objetivo entrenar un modelo de clasificación de aprendizaje supervisado para realizar la mejor predicción de condición de pobreza de los hogares en Colombia con base en diferentes variables sociodemográficas y económicas.

La iniciativa sobre Pobreza y Desarrollo Humano (OPHI) de la Universidad de Oxford y la Oficina del Informe sobre Desarrollo Humano del Programa de las Naciones Unidas para el Desarrollo creó el Índice de pobreza multidimensional (IPM), que mide la pobreza con base en los Objetivos de Desarrollo Sostenible (ODS). El IPM recoge información sobre las privaciones de los hogares en dimensiones como (i) estándares de vida: disponibilidad de servicios públicos, condiciones de la vivienda, modo de cocinar los alimentos, activos; (ii) salud: nutrición y mortalidad infantil y (iii) educación: años de escolaridad y asistencia escolar (United Nations Development Programme and Oxford Poverty and Human Development Initiative, 2024). En ese sentido, la pobreza se define como la privación de capacidades esenciales para llevar una vida digna que, aunque en principio va más allá de la falta de ingresos, se relaciona con la generación de estos (Sen, 1999).

Existe amplia evidencia de la relación entre la provisión de servicios públicos, la salud y la educación, así como de la educación y el ingreso. Revisiones sistemáticas encuentran que la provisión de agua y saneamiento básico mejora la salud y nutrición infantil a través de la reducción de enfermedades gastrointestinales o respiratorias. Esto tiene impacto también en la población adulta y, entre mayor sea la cobertura en la comunidad, mejores resultados se obtienen. Las externalidades positivas de este servicio son que, con una mejor salud infantil, se favorece la asistencia escolar; se ahorra tiempo en la recolección de agua por parte de los hogares, se reducen conflictos por agua y se libera tiempo para educación y empleo (Maris, 2023). Asimismo, el acceso a la electricidad mejora las condiciones de vida al facilitar el uso de iluminación, electrodomésticos y servicios como agua potable, además de permitir más actividades recreativas, dedicar más tiempo de estudio en el hogar y mayor productividad en actividades del hogar. Asimismo, tener acceso a electricidad impacta la salud, se reduce la exposición a fuentes de polución por cocinar con combustibles u otros materiales, esto reduce enfermedades de los ojos, respiratorias, cardiovasculares y/o diarreicas (Paniagua, 2023).

Por su parte, se ha documentado que el nivel de educación es un buen predictor, entre otros, de los ingresos, lo que evidentemente apalanca mejores condiciones de vida. Se establece la relevancia de la educación en la pobreza a través de la generación de ingresos con base en la ecuación de Mincer, fundamentada en la teoría del capital humano y respaldada por la evidencia empírica (Grossbard, 2006). La educación y la experiencia representan la acumulación de habilidades que aumentan la productividad y los ingresos.

Para la predicción de la condición de pobreza, se utilizaron los datos de la GEIH y la MESEP disponibles en *Kaggle*, a partir de los cuales se construyó una base de corte transversal a nivel de hogar que integra información individual y del hogar. Esta base permite caracterizar condiciones sociodemográficas relevantes mediante variables como

ocupación, educación y hacinamiento, entre otras. Se eliminaron registros con valores faltantes clave y se aplicó un proceso de *undersampling* para balancear la variable objetivo (condición de pobreza), sin alterar la distribución del resto de variables.

La disponibilidad de datos con la que contamos no incluye acceso a servicios de salud, sin embargo, está la variable de afiliación a salud por tipo de régimen: contributivo o subsidiado. En Colombia, la cobertura de afiliación en salud es mayor al 90 %, siendo mayor en zonas urbanas (Núñez, 2023), por lo que el diferencial se observa por régimen de afiliación. Quienes están en régimen contributivo aportan un monto mensual para este servicio, lo que puede indicar que tienen capacidad en términos de ingreso para hacerlo y un menor grado de vulnerabilidad económica de la familia. Por su parte, el caso de quienes están en régimen subsidiado sugiere que el hogar no tiene ingresos suficientes para financiar este servicio, lo que puede ser un indicador de pobreza.

En cuanto a indicadores de salud y condiciones de vivienda, se dispone con información de hacinamiento que puede generar una aproximación a condiciones de salud y bienestar. Varios estudios han identificado asociaciones entre el hacinamiento y factores como insalubridad y malas condiciones estructurales que influyen en la salud (Lorentzen et al., 2022). No obstante, según los mismos autores en la gran mayoría de los estudios de la revisión sistemática (94 de 100) se encontró que existen diversas condiciones de vida potencialmente peligrosas que suelen coincidir en hogares con hacinamiento, como factores sociales y ambientales que también afectan la salud. En ese sentido, esta variable podría capturar factores subyacentes de la pobreza como ubicación de la vivienda y la disponibilidad de servicios públicos.

Los factores sociodemográficos del hogar, como la edad y el género del jefe, han demostrado influir en los niveles de pobreza. La evidencia empírica indica que los hogares cuyo jefe pertenece a un grupo etario más alto tienen una menor probabilidad de permanecer en la pobreza (Meng et al., 2007). Asimismo, la composición etaria del hogar también incide en esta probabilidad. Mok et al. (2007) encuentran que una mayor proporción de niños menores de 15 años y de mujeres adultas en el hogar incrementa la posibilidad de que este sea pobre. En cuanto al género, la literatura señala que las mujeres y las niñas enfrentan un mayor riesgo de pobreza en comparación con los hombres (Terry, 2004), debido a barreras estructurales que limitan su acceso al empleo formal, la educación y los recursos económicos. Además, normas sociales restrictivas y la distribución desigual del trabajo no remunerado refuerzan esta vulnerabilidad, perpetuando ciclos de pobreza y desigualdad (UN Women, 2015). Por ello, nuestras estimaciones incluyen variables como la edad y el sexo del jefe del hogar, así como el número de menores en la vivienda.

Por otro lado, las características estructurales del hogar también están estrechamente relacionadas con la pobreza. (Cancian and Haskins, 2014) destacan que las familias monoparentales encabezadas por una mujer tienen una probabilidad cinco veces mayor de ser pobres en comparación con los hogares biparentales. Asimismo, el tamaño del hogar y el número de dependientes, son factores determinantes. Widyanti et al. (2010) señalan que los hogares más numerosos tienen mayor probabilidad de experimentar pobreza, mientras que Sikander and Ahmed (2008) encuentran que un incremento en el índice de dependencia contribuye en casi un 4 % al aumento de la probabilidad de pobreza.

La región donde se ubica el hogar es un factor clave en la determinación de sus ingresos, particularmente en Colombia donde los pobres rurales extremos son 3,2 veces más pobres

que los urbano (Departamento Nacional de Planeación, 2012), por lo cual, la zona donde se ubica el hogar es otra variable que consideramos en los modelos.

Las características ocupacionales de los hogares están estrechamente relacionadas con sus niveles de ingreso. El empleo suele considerarse la mejor protección contra la pobreza. La literatura ha demostrado que las transiciones en el mercado laboral tienen un impacto significativo en la movilidad de los hogares hacia o fuera de la pobreza (Polin and Raitano, 2014). Además, los empleos formales suelen ofrecer mayor estabilidad laboral, lo que puede influir en la probabilidad de que un hogar sea pobre. Por esta razón, nuestros modelos incorporan variables que permiten identificar la distribución de la fuerza laboral dentro del hogar (ocupados, desocupados e inactivos). Asimismo, incluimos una variable que indica si el jefe del hogar cotiza a un fondo de pensiones, ya que, particularmente en Colombia, la cotización a un sistema de pensiones suele estar asociada con empleos más estables y mejor remunerados, lo que reduce la vulnerabilidad económica del hogar.

El mejor modelo fue XGBoost, optimizado para F1-score (0.6962 en *Kaggle*), usando sobremuestreo (SMOTE), validación cruzada y ajuste fino de hiperparámetros. Se evaluaron otros modelos (Logit: 0.6013, Elastic Net: 0.5680, Naive Bayes: 0.4585, Bagging: 0.5878, Random Forest: 0.6018, AdaBoost: 0.6492), pero XGBoost destacó por su selección de variables, balanceo de clases y alineación con la métrica F1 (ver cuadro 5). En conclusión, de este mejor modelo predictivo de pobreza (XGBoost) se destacan variables del jefe del hogar (como afiliación al régimen subsidiado), composición del hogar y condiciones habitacionales. El balanceo de clases mejoró el desempeño. Se sugiere incorporar variables de salud, vivienda y programas sociales, así como explorar redes neuronales para mejorar la predicción: resultados del concurso de predicción de pobreza del Banco Mundial muestran mejores resultados con dichos modelos.

Este documento está dividido en 5 secciones, la primera es introducción, la segunda sección de datos, en la que se esbozan las fuentes de información, las variables utilizadas y estadísticas descriptivas; en la sección 3 se describen los modelos estimados, la elección de hiperparámetros, la relevancia de las variables en la predicción de la condición de pobreza, entre otros detalles, la sección 4 presenta las conclusiones del documento. Finalmente, la sección 5 es el apéndice del documento.

2. Datos


A partir de la Gran Encuesta Integrada de Hogares (GEIH) y los datos de la Misión para el Empalme de las Series de Empleo, Pobreza y Desigualdad (MESEP), se construyó una base de datos de corte transversal con información a nivel de hogar, que integra tanto variables individuales como del hogar. Esta base construida es especialmente útil para la medición y predicción de la pobreza, ya que permite caracterizar las condiciones sociodemográficas de los hogares, insumos clave para identificar con precisión a la población en situación de pobreza. La GEIH recopila información tanto a nivel individual como hogar sobre la población en Colombia, es una fuente clave para generar indicadores, principalmente, de mercado laboral (formalidad, ocupación, ingresos y sus fuentes). Asimismo, permite extraer información de características demográficas básicas como sexo, nivel educativo, edad, afiliación a seguridad social, número de personas en el hogar, entre otras.

Por su parte, la MESEP contiene series empalmadas y comparables de empleo, pobreza y desigualdad en Colombia, construidas por el DANE y el DNP a nivel hogar. La base permite estimar pobreza, pobreza extrema y desigualdad a partir de datos derivados de encuestas de hogares, y constituye la fuente oficial para el seguimiento de estos indicadores en el país a través de la estimación de líneas de pobreza monetaria y pobreza multidimensional. (Departamento Administrativo Nacional de Estadística (DANE), 2017). Los datos tienen cobertura nacional y permiten desagregación por zona, región y nivel geográfico. Como muestra el cuadro 3 del apéndice (sección 5), la distribución de hogares en las bases *train* y *test* es similar, sin generar desbalance para la predicción.

La base final usada en este documento fue construida combinando las bases de datos *train_personas* y *train_hogares* suministradas en *Kaggle*, que contenían información de la GEIH y MESEP, las bases fueron unidas usando la variable *id* del hogar. Se realizó una limpieza de eliminación de *NAs* en la variable del régimen de salud del jefe del hogar, se perdieron 3 observaciones. También se agregaron variables a nivel de hogar como el número de ocupados, desocupados (también como proporción sobre la PET), número de menores y adultos mayores dependientes, medidas del nivel educativo, y hacinamiento (personas por habitación), entre otras. Se crearon nuevas variables a nivel individual, transformando variables categóricas en indicadores binarios y ajustando valores faltantes.

Asimismo, se aplicó un proceso de *undersampling* para balancear la clase “Pobre”, dado que inicialmente la categoría “No pobre” representaba solo el 20 % de las observaciones (ver figura 1). Tras este proceso, la clase quedó completamente balanceada, como se observa en el panel derecho de la figura 1. Cabe resaltar que este proceso no afecta la distribución de las demás variables para las observaciones que fueron “ampliadas”

Figura 1. Distribución porcentual de la variable “Pobre” por base *train*



Nota: la muestra *train* tiene 164.960 observaciones, mientras que la muestra muestra balanceada (*upsampling*) tiene 263.872. Los resultados en términos de distribución para los demás variables se mantienen para ambas muestras: *train* original y *train upsampling*. Fuente: Elaboración propia. Naus (2025) con base en GEIH y MESEP (s.f.)

La elección de las variables para este análisis se fundamentó en una revisión de la literatura sobre las principales dimensiones que afectan la pobreza. En primer lugar, se seleccionaron variables basadas en el Índice de Pobreza Multidimensional (IPM), desarrollado por la Universidad de Oxford y el Programa de las Naciones Unidas para el

Desarrollo, que mide la pobreza a través de dimensiones como estándares de vida, salud y educación (United Nations Development Programme and Oxford Poverty and Human Development Initiative, 2024).

Se incluyó el nivel de educación del jefe del hogar, ya que es un predictor de ingresos, siguiendo la teoría del capital humano (Grossbard, 2006), lo que a su vez se relaciona con la condición de pobreza. También se incorporó una variable relacionada con las condiciones de vivienda, como el hacinamiento, que se ha asociado con la salud y el bienestar (Lorentzen et al., 2022). Se tiene también que la provisión de servicios públicos como agua, saneamiento y electricidad tienen un impacto directo en la salud, educación e ingresos, factores determinantes del IPM (Maris, 2023, Paniagua, 2023). Sin embargo, dado que no se dispone de datos directos sobre acceso a servicios de salud o servicios públicos, se utilizó la afiliación a salud por régimen como un indicador asociado con bienestar económico y de acceso a servicios de salud.

Por otro lado, se incluyeron factores sociodemográficos, como la edad y el género del jefe de hogar, que influyen en la probabilidad de pobreza (Meng et al., 2007, Terry, 2004). Finalmente, se consideraron características estructurales del hogar, como el tamaño y la composición familiar (menores y mayores), y la ubicación del hogar (dominio, ver cuadro 3), ya que se sabe que la pobreza es más prevalente en áreas rurales en Colombia (Departamento Nacional de Planeación, 2012). Además, se incorporaron variables sobre características ocupacionales, como el empleo y la afiliación a un sistema de pensiones, factores clave en la determinación de la vulnerabilidad económica (Polin and Raitano, 2014).

En los cuadros 1 y 2 se observa que existen consistentemente diferencias entre hogares pobres y no pobres. En el cuadro 1 se tiene que los hogares pobres se concentran más en zonas rurales (14,1 %) que los no pobres (8,2 %). En términos laborales, solo el 64,3 % de los jefes de hogar pobres están ocupados frente al 72,7 % de los no pobres, y apenas el 7,9 % de los primeros cotiza a pensión, frente al 35,4 % de los segundos. En educación, los jefes de hogar pobres presentan una menor proporción con nivel universitario (10,3 %) respecto a los no pobres (31,5 %) y una mayor proporción con educación primaria o ninguna. Además, una mayor proporción de hogares pobres está afiliada al régimen subsidiado de salud (82,5 %) frente a los no pobres (37,1 %). También presentan menores niveles de propiedad de la vivienda (29,2 % pobres vs. 44,2 % no pobres). Se destaca que los jefes de hogar pobres están más representados en el trabajo por cuenta propia (47,3 %) que los no pobres (32,2 %), y menos en trabajos asalariados (14,7 % pobres vs. 35,6 % no pobres).

Las diferencias también son notorias entre hogares pobres y no pobres en variables como años promedio de educación, hacinamiento, fuentes de ingreso y algunas proporciones (cuadro 2). Los hogares pobres presentan menores niveles de educación: el promedio de años de educación de los miembros del hogar mayores de 15 años es de 7,6 años frente a 10,2 en hogares no pobres. Además, el número promedio de fuentes de ingreso por hogar es considerablemente menor entre los pobres (1,2) en comparación con los no pobres (2,8), lo cual también se refleja en una menor proporción de fuentes de ingreso por persona (0,32 vs. 1,01). Las fuentes de ingresos incluye las laborales, como primas, censantías, bonificaciones, horas extras, variables que podrían reflejar la calidad del empleo; así como ingresos no laborales: arriendos, pensiones o ayudas del gobierno.

Cuadro 1. Distribución porcentual por variable categórica según condición de pobreza y total - Bases *train* y *test*

Variable	Categoría	Base <i>train</i>		Base <i>test</i>	
		Pobre	No pobre	Total	Total
Clase	Cabecera	85,9	91,8	90,6	89,9
Clase	Resto	14,1	8,2	9,4	10,1
Cotiza pensión jefe hogar	No	92,1	64,6	70,1	70,8
Cotiza pensión jefe hogar	Si	7,9	35,4	29,9	29,2
Estado ocupación jefe hogar	No ocupado	35,7	27,3	29,0	28,9
Estado ocupación jefe hogar	Ocupado	64,3	72,7	71,0	71,1
Jefe hogar mayor	No	39,8	51,7	49,3	49,4
Jefe hogar mayor	Si	60,2	48,3	50,7	50,6
Jefe hogar mujer	No	46,8	40,6	41,8	41,6
Jefe hogar mujer	Si	53,2	59,4	58,2	58,4
Nivel educación jefe hogar	Media	25,3	26,3	26,1	25,7
Nivel educación jefe hogar	Ninguno	10,3	3,9	5,2	5,5
Nivel educación jefe hogar	Primaria	37,8	25,9	28,3	28,7
Nivel educación jefe hogar	Secundaria	16,2	12,4	13,2	13,1
Nivel educación jefe hogar	Universitaria	10,3	31,5	27,2	26,9
Propiedad vivienda	Con vivienda	29,2	44,2	41,2	41,1
Propiedad vivienda	Sin vivienda	70,8	55,8	58,8	58,9
Régimen salud jefe hogar	Contributivo	17,5	62,9	53,8	52,5
Régimen salud jefe hogar	Subsidiado	82,5	37,1	46,2	47,5
Tipo ocupación	No ocupado	35,7	27,3	29,0	28,9
Tipo ocupación	Ocup asalariado	14,7	35,6	31,4	30,4
Tipo ocupación	Ocup otro	0,8	0,4	0,5	0,5
Tipo ocupación	Ocup patrón	1,5	4,5	3,9	3,9
Tipo ocupación	Ocup cuenta propia	47,3	32,2	35,2	36,3

Nota: la tabla fue realizada con la muestra *train* (Obs. 164.960), los resultados en términos de distribución son iguales para la muestra *train* con la muestra balanceada *upsampling* (Obs. 263.872) Fuente: Elaboración propia. Naus (2025) con base en GEIH y MESEP (s.f.)

También se observa que los hogares pobres son más numerosos (4,1 personas en promedio vs. 3,1 hogares no pobres) y tienen mayor presencia de menores (0,64 menores por hogar pobre vs. 0,26 por hogar no pobre), lo que se traduce en una mayor proporción de menores dentro del hogar (13 % vs. 6 %). Asimismo, los hogares pobres tienen una menor proporción de ocupados dentro de la población en edad de trabajar (PET) (31 % vs. 54 %) y una mayor proporción de inactivos (37 % vs. 30 %). También presentan mayores niveles de hacinamiento (1,53 personas por dormitorio vs. 0,95 en hogares no pobres), una mayor cantidad de mujeres (3,24 vs. 2,62 hogares no pobres) y una edad promedio más baja del jefe de hogar (46,8 años vs. 50,3 años jefe hogar no pobre). Estas diferencias reflejan condiciones estructurales que afectan las oportunidades de generación de ingresos y bienestar de los hogares pobres, lo que respalda la relevancia de las variables incluidas para la identificación de hogares pobres.

Cuadro 2. Distribución porcentual de variables continuas según condición de pobreza y total - Bases *train* y *test*

Variable	Base <i>train</i>		Base <i>test</i>	
	Pobre	No pobre	Total	Total
Años promedio edu hogar	23,3	27,2	26,4	26,3
Desocupados hogar	0,3	0,2	0,2	0,2
Edad jefe hogar	46,8	50,3	49,6	49,7
Fuentes ingresos hogar	1,2	2,8	2,5	2,4
Hacinamiento	1,5	1,0	1,1	1,1
Inactivos	1,5	0,9	1,0	1,0
Mayores dependientes hogar	0,3	0,3	0,3	0,3
Menores	0,6	0,3	0,3	0,3
Mujeres	3,2	2,6	2,7	2,8
Ocupados	1,3	1,6	1,5	1,5
Personas hogar	4,1	3,1	3,3	3,3
Pet	3,0	2,6	2,7	2,7
Promedio años educ > 15 años	7,6	10,2	9,6	9,5
Proporción fuentes ingresos / persona	0,3	1,0	0,9	0,8
Proporción inactivos/pet	0,4	0,3	0,3	0,3
Proporción ocupados/pet	0,3	0,5	0,5	0,5
Proporción mayores hogar	0,1	0,1	0,1	0,1
Proporción menores hogar	0,1	0,1	0,1	0,1
Línea pobreza	265.302,5	273.079,2	271.522,3	270.984,5

Nota: la tabla fue realizada con la muestra *train* (Obs. 164.960), los resultados en términos de distribución son iguales para la muestra *train* con la muestra balanceada *upsampling* (Obs. 263.872) Fuente: Elaboración propia. Naus (2025) con base en GEIH y MESEP (s.f.)

3. Modelos y resultados

3.1. Selección del mejor modelo y entrenamiento

El modelo con el mayor puntaje F1 fue estimado por medio de XGBoost. El XGBoost (eXtreme Gradient Boosting) es una biblioteca de *machine learning* que emplea árboles de decisión basados en gradiente, combinando árboles de aprendices débiles en aprendices fuertes sumando residuos (Kavlakoglu & Russi, 2024). La especificación del modelo final estimado es la siguiente, cuya descripción de las variables y su importancia en la estimación pueden verse en la sección 3.4:

$$\begin{aligned} \text{Pobre} = & \beta_1 \text{jefe_salud_sub} + \beta_2 \text{prop_ocu_pet} + \beta_3 \text{prop_fuentes_ing} + \beta_4 \text{max_nivel_educ} + \\ & \beta_5 \text{hacinamiento} + \beta_6 \text{tipo_trabajo} + \beta_7 \text{pago_arriendo} + \beta_8 \text{viv_noPropia} + \\ & \beta_9 \text{prop_menores12_pob} + \beta_{10} \text{prop_anios_educ} + \beta_{11} \text{jefe_mujer} + \beta_{12} \text{jefe_pension} + \\ & \beta_{13} \text{N_mujer} + \beta_{14} \text{prop_ina_pet} + \beta_{15} \text{N_personas} + \beta_{16} \text{jefe_ocu} + \beta_{17} \text{prop_des_pet} + \\ & \beta_{18} \text{Lp} + \beta_{19} \text{jefe_edad} + \beta_{20} \text{jefe_edad2} + \beta_{21} \text{prop_mayores_pob} + \beta_{22} \text{Clase} + \beta_{23} \text{Dominio} \end{aligned}$$

Con el fin de predecir la probabilidad de que una persona se encuentre en situación de pobreza, se entrenó un modelo de clasificación utilizando el algoritmo XGBoost mediante el paquete `caret` en R. Dada la naturaleza desbalanceada del problema, donde la clase “Pobre” es minoritaria, se implementó una estrategia de sobremuestreo con SMO-TE dentro de cada pliegue de validación cruzada, lo cual permite mejorar la capacidad predictiva sobre la clase minoritaria sin alterar la distribución global de los datos. El entrenamiento se realizó sobre la base de entrenamiento brindada en *Kaggle*, especificando como variable dependiente *Pobre* y un conjunto de variables explicativas definidas anteriormente. El modelo fue estimado utilizando una validación cruzada de 5 pliegues (5-fold cross-validation), configurada con los siguientes parámetros:

- `summaryFunction = fiveStats`: función personalizada que calcula F1 Score, AUC y sensibilidad.
- `sampling = smote`: sobremuestreo sintético de la clase minoritaria dentro de cada pliegue.
- `savePredictions = all`: guarda todas las predicciones de cada pliegue para su evaluación posterior.
- `classProbs = TRUE`: habilita la predicción de probabilidades para métricas como AUC.

Para afinar el desempeño del modelo, se definió una grilla de hiperparámetros (`grid_xgboost`) que exploró combinaciones de:

- `nrounds`: número de iteraciones (250 y 500),
- `max_depth`: profundidad máxima de los árboles (3, 5 y 7),
- `eta`: tasa de aprendizaje (0.05 y 0.1),
- `gamma`: penalización por complejidad de los árboles (0, 0.1 y 1),
- `min_child_weight`: mínimo número de observaciones por nodo (1, 3 y 5),
- `colsample_bytree`: proporción de variables por árbol (0.6 y 0.8),
- `subsample`: fracción de muestras usada en cada árbol (0.7).

El criterio de selección del mejor modelo fue el *F1 score*, dado el énfasis en la correcta clasificación de la clase minoritaria “Pobre”. Finalmente, el modelo entrenado (*Xgboost_tree*), cuyo resultado fue el que mejor obtuvimos en *Kaggle* con un *F1* de 0.6962, nos arroja los siguientes hiperparámetros: `nrounds=500`; `max_depth=7`; `eta=0.05`; `gamma=0`; `min_child_weight=5`; `colsample_bytree=0.6`; `subsample=0.7` (ver Tabla 5). Adicionalmente, usando *R* se buscó el umbral óptimo de clasificación para un modelo *XGBoost*, con el objetivo de maximizar el *F1 Score*, obteniendo un umbral óptimo de 0.36.

La configuración de hiperparámetros óptima tras el proceso de validación cruzada, permitió obtener un balance entre profundidad y regularización, lo que favoreció una buena generalización sin sobreajuste, especialmente con un `min_child_weight=5` suficientemente alto para controlar nodos poco representativos y un `gamma` nulo, que permitió mayor crecimiento de árboles. El sobremuestreo también jugó un papel clave en las estimaciones por *XGBoost*, ya que al utilizar SMOTE (Synthetic Minority Oversampling Technique), se logró balancear la clase minoritaria (“Pobre”) y mejorar la sensibilidad del modelo sin degradar la precisión. Asimismo, fue útil usar la métrica a optimizar, que fue el *F1 score*, adecuada en contextos de desbalance de clases como este ejercicio.

3.2. Ajuste de hiperparámetros diferentes metodologías y modelos estimados

En el caso de la metodología de regresión logística, se estimaron 6 modelos, el mejor en términos de la métrica *F1* fueron el modelo 4 y 6 (ver cuadro 4) y se usaron, en promedio, 13 predictores. Este modelo no contiene hiperparámetros. Por su parte, para entrenar el modelo de clasificación a través de Elastic Net y realizar una selección óptima de los hiperparámetros, se utilizó validación cruzada con una estrategia de búsqueda en grilla. El hiperparámetro *alpha*, que determina el peso relativo entre las penalizaciones Ridge ($\alpha = 0$) y Lasso ($\alpha = 1$), fue evaluado en incrementos de 0.15, es decir: 0.00, 0.15, 0.30, ..., 1.00. Por su parte, el hiperparámetro λ , que controla la intensidad de la penalización, fue evaluado en una escala logarítmica con 100 valores uniformemente distribuidos entre 10^2 y 10^{-6} .

La elección de estos rangos se justifica por dos razones principales. Primero, se busca capturar una amplia gama de combinaciones que permitan explorar desde modelos fuertemente penalizados hasta aquellos con mínima regularización, así como diferentes grados de mezcla entre penalizaciones Lasso y Ridge. Segundo, debido a restricciones en la capacidad computacional disponible, no fue viable implementar una grilla más fina. Por tanto, se optó por un compromiso entre precisión en la búsqueda y eficiencia computacional. Para cada una de las combinaciones de hiperparámetros, se estimó el desempeño utilizando validación cruzada de cinco pliegues. Finalmente, se seleccionó como modelo óptimo aquel que maximizó el *F1-score* en la muestra de validación. Figura 3 de la sección 5 (apéndice) presenta el *F1* resultante de la combinación de las distintas combinaciones de α y λ especificados, destacando la que mejor *F1* genera para los 4 modelos especificados con Elastic Net.

Para el modelo de clasificación Naive Bayes, no se realizó una búsqueda activa de hiperparámetros, ya que se utilizaron los valores por defecto. El hiperparámetro Laplace se fijó en 0, lo que significa que no se aplicó suavizado, ya que no se encontraron categorías con frecuencia cero en las variables. El parámetro *adjust* se estableció por defecto en

1 cuando `usekernel = TRUE`, lo que controla la suavidad de la función de densidad estimada. En el modelo de *bagging* se entrenaron 500 árboles, utilizando 8 variables aleatorias por división (de un total de 17 variables predictoras) y un tamaño mínimo de nodo de 1, lo que permite árboles más profundos. Dado que en esta metodología el número de árboles no es un parámetro crítico, se optó por el valor por defecto.

Por otra parte, construyó un árbol de decisión *CART* utilizando la función `rpart`, fijando el parámetro de complejidad $\alpha = 0$ y un mínimo de 15 observaciones por hoja. Posteriormente, el árbol fue podado seleccionando el valor óptimo de α que minimiza el error de validación cruzada. A pesar del ajuste, el modelo obtuvo un AUC de 0.4934 en Kaggle, indicando un desempeño por debajo del azar y una baja capacidad predictiva.

También, se implementó un modelo de Random Forest utilizando 500 árboles (`num.trees = 500`), seleccionando aleatoriamente 4 variables por partición (`mtry = 4`), con un tamaño mínimo de nodo de 1 (`min.node.size = 1`), y calculando la importancia de las variables con el criterio de impureza (`importance = impurity`). El modelo obtuvo un AUC de 0.6018 en *Kaggle*, lo que refleja un desempeño moderado. Se probaron configuraciones con 2000 árboles y `mtry = 8`, pero no se observó mejora en el rendimiento. Esto se debe probablemente al sobreajuste al aumentar la complejidad del modelo y a que el número de árboles inicial ya era suficiente, mientras que un valor más alto de `mtry` no aportó beneficios adicionales en este caso.

3.3. Análisis comparativo

Se utilizan 6 algoritmos de clasificación: Regresión logística, *Elastic Net*, *Naive Bayes*, *CARTs*, *Random Forest*, *Bagging* y *Boosting*. Iniciamos con el uso de métodos de clasificación más simples como la regresión logística. Aunque se exploraron distintas formas funcionales e interacciones entre variables, este modelo presenta limitaciones importantes en la capacidad predictiva. Esto se debe a que la relación entre las variables observadas y la pobreza es altamente no lineal y compleja, lo que dificulta que modelos paramétricos tradicionales capten adecuadamente estos patrones.

Además, en el caso de la regresión logística, el modelo está diseñado para minimizar el error dentro de muestra, pero no necesariamente optimiza el desempeño fuera de muestra. Esto puede llevar a un problema de sobreajuste. Por esta razón, recurrimos al uso de métodos de regularización, en particular *Elastic Net*, que busca mejorar la capacidad predictiva fuera de muestra al reducir la varianza, mitigar la colinealidad entre predictores y disminuir la influencia de variables poco relevantes. Sin embargo, el rendimiento de estos modelos no generó una mejoría en las métricas evaluadas. Para ajustar modelos más flexibles pero aún interpretables, recurrimos inicialmente a métodos basados en árboles de clasificación. Sin embargo, dado que los árboles individuales no son especialmente robustos, y que su desempeño puede mejorarse sustancialmente mediante técnicas de agregación, avanzamos hacia métodos de ensamble como *Bagging*, *Random Forests* y *Boosting*, que permiten mejorar la capacidad predictiva del modelo.

Estos métodos mejoraron las métricas de *performance predictive*, siendo los modelos que usan *Boosting* los que generaron los 5 mejores puntajes en *Kaggle*. Esto puede deberse a que *Boosting*, al corregir secuencialmente los errores de modelos anteriores, es capaz de capturar relaciones complejas y patrones sutiles en los datos. Además, suele

desempeñarse bien en contextos con clases desbalanceadas, como en nuestro caso, ya que asigna mayor peso a los casos difíciles de clasificar, es decir, a los hogares pobres, que están subrepresentados en la muestra.

Los cinco modelos con mejor capacidad predictiva utilizaron algoritmos de Boosting, específicamente AdaBoost y XGBoost. Sin embargo, AdaBoost mostró un rendimiento inferior en las métricas de evaluación en comparación con XGBoost. Como se observa en tabla 5, el modelo con mejor desempeño en el concurso fue XGBoost 4 (final), el cual alcanzó un F1-score de 0.6962. Este modelo superó a las otras versiones principalmente por su cuidadosa selección de variables, su alineación con la métrica de evaluación (optimización directa del F1-score), y el uso de técnicas de balanceo de clases que mejoraron sustancialmente la identificación de los hogares en condición de pobreza. En particular, el modelo incorporó variables que abarcan todas las dimensiones que tiene el cuenta el IPM. Se incluyeron características sociodemográficas y laborales tanto del jefe del hogar como del hogar en su conjunto, lo que permitió capturar información clave sobre los niveles educativos, la composición del hogar, su estructura ocupacional así como información de las fuentes de ingresos. Esta especificación fue acompañada por un ajuste fino de hiperparámetros y validación cruzada, lo cual favoreció la estabilidad del modelo.

Al comparar este modelo con los siguientes 4 mejores modelos del concurso, se identifican diferencias importantes que explican las brechas en desempeño. Por ejemplo, XGBoost 3, con un F1 de 0.6907, excluyó algunas variables clave como la proporción de personas sin educación, el número de mujeres en el hogar o si el jefe estaba ocupado, e incluyó una variable menos precisa de proporción de menores de 6 años, en lugar de menores de 12. Además, aunque mantuvo la misma profundidad, número de iteraciones, tasa de aprendizaje y penalización por complejidad que el mejor modelo ($max_depth = 7$, $nrounds = 500$, $eta = 0.05$, $gamma = 0$), utilizó un menor min_child_weight y $colsample_bytree$, lo que hace que el modelo sea más flexible y utilice una mayor proporción de características de los árboles, a costa de un mayor riesgo de sobreajuste, reduciendo levemente su capacidad predictiva.

XGBoost 2, con menor número de iteraciones ($nrounds = 250$) y valores similares para otros hiperparámetros, mostró un descenso más marcado ($F1 = 0.6743$) al omitir variables educativas y laborales relevantes, además de no considerar la proporción de personas con pensión. Aunque utilizó F1 como métrica de optimización, la exclusión de estas variables redujo la sensibilidad del modelo frente a hogares pobres. XGBoost 1, por su parte, tuvo un F1-score de 0.6339, el más bajo entre los XGBoost, lo cual puede explicarse por el uso de ROC como métrica en lugar de F1, la ausencia de sobremuestreo de la clase minoritaria, la exclusión de una parte importante de variables informativas y el uso de una tasa de aprendizaje extremadamente baja ($eta = 0.01$), lo cual pudo ralentizar el aprendizaje sin suficiente número de iteraciones compensatorias.

Por otro lado, los modelos AdaBoost obtuvieron resultados más modestos en comparación con los modelos basados en XGBoost. AdaBoost 2, con un F1 de 0.6492, usó una especificación parecida a XGBoost 3, pero sin balanceo de clases ni un ajuste tan detallado de hiperparámetros, lo cual limitó su capacidad predictiva. En contraste, AdaBoost 1, con un F1-score de 0.6099, presentó el desempeño más bajo entre los cinco mejores modelos. Esto puede deberse a que no utilizó la métrica F1 como criterio de optimización ni aplicó técnicas de balanceo de clases.

En resumen, los resultados muestran que el mejor desempeño se logra cuando se alinean cuatro factores: una selección informada de variables explicativas, el uso de una métrica de optimización coherente con el objetivo del modelo (en este caso, el F1-score), una configuración bien ajustada de hiperparámetros que balancean profundidad, complejidad y regularización y técnicas que aborden el desbalance en las clases. Los modelos que ignoraron uno o más de estos elementos obtuvieron puntajes inferiores, evidenciando la importancia de una estrategia integral de especificación, entrenamiento y evaluación del modelo.

3.4. Relevancia variables en entrenamiento mejor modelo

El modelo estimado por XGBoost con la mejor predicción nos arrojó una importancia de las variables utilizadas que puede observarse en la Figura 2. Las variables más representativas son las relacionadas con afiliación a seguridad social en salud, proporción de ocupados y fuentes de ingreso. A partir de dicha clasificación resultado del ejercicio de estimación realizado, a continuación, se presenta una breve explicación de las principales variables y su importancia para mejorar las predicciones del modelo.

1. **jefe_salud_sub** toma el valor de 1 si la persona está afiliada a seguridad social en régimen subsidiado y 0 en contributivo. El acceso a un sistema de salud de calidad condiciona profundamente el desarrollo intelectual, económico, productivo y social (DANE, 2012).
2. **prop_ocu_pet** es la cantidad de personas ocupadas del hogar sobre el total de personas que conforman este. Un mayor número de personas ocupadas es un indicador de mayores ingresos, lo que reduce la posibilidad de un hogar en la pobreza.
3. **prop_fuentes_ing** es la suma de la cantidad de variables de ingresos monetarios y en especie que cada persona manifestó recibir sobre el total de personas del hogar. Una mayor cantidad de posibles fuentes de ingresos del hogar reduce la probabilidad de que este sea pobre.
4. **max_nivel_educ** es el nivel educativo del jefe del hogar. Las personas con un nivel educativo más alto tienen mayores ingresos que aquellos con niveles más bajos, por tanto, reduce la posibilidad de caer en la pobreza.
5. **hacinamiento** es el número de personas en el hogar sobre el total de cuartos. Un mayor nivel de este es un indicador de la precariedad de las condiciones de vivienda de los hogares en situación de pobreza (MacDonald, 2004).
6. **tipo_trabajo** especifica si el jefe de hogar se encuentra empleado como cuenta propia, asalariado, patrón o empleador o no está empleado. La superación de la pobreza está relacionada con la inclusión social a través de la garantía de un empleo formal (DANE), 2014). Por tanto, hogares con un jefe de hogar en condiciones de informalidad laboral como los empleados por cuenta propia tienen más probabilidades de estar en la pobreza.
7. **pago_arriendo** clasifica a los hogares si pagan un arriendo con valor bajo, medio y alto o si no pagan arriendo. La falta de propiedad de la vivienda en relación con un arriendo bajo (menor a \$500.0000) puede estar relacionado con hogares más pobres. Asimismo, el gasto en vivienda representa una proporción considerable del

ingreso de los hogares, especialmente entre los más vulnerables. Este es uno de los componentes más importantes del gasto en vivienda, y su peso relativo tiende a ser mayor en los hogares de menores ingresos (Observatorio del Hábitat, 2020).

8. `viv_noPropia` es una variable que toma el valor de 1 si el hogar vive en una vivienda no propia y 0 de lo contrario. Las personas que no son propietarias de su vivienda suelen enfrentar mayores riesgos económicos debido a los altos costos asociados al alquiler, lo que puede perpetuar la pobreza al restarles recursos para cubrir otras necesidades básicas (Baker and Bentley, 2011).
9. `prop_menores12_pob` es la cantidad de personas de 12 años y menos en el hogar sobre el total de personas de este. `prop_mayores_pob` está construida bajo la misma lógica para las personas de 60 años y más. A mayor número de menores de 12 años o personas mayores de 60 años en el hogar, mayor es la carga de cuidado que deben asumir los adultos, especialmente las mujeres. Esta carga implica tiempo, energía y recursos que no pueden destinarse a trabajo remunerado, educación o actividades generadoras de ingreso (ONU Mujeres Colombia and DANE, 2020).
10. `prop_anios_educ` es la suma de los años de educación de cada persona en el hogar sobre el total de personas que conforman este. Hogares con menos años de educación promedio tendrían mayores probabilidades de ser pobres en tanto que puede dificultárseles acceder a oportunidades laborales. Existe una fuerte interdependencia entre el bajo nivel educativo y la pobreza, lo que contribuye a la reproducción intergeneracional de esta (INEI, 1999).
11. `jefe_mujer` es una variable que toma el valor de 1 si la persona jefa del hogar es una mujer y 0 de lo contrario. Los hogares liderados por mujeres tienen una mayor vulnerabilidad económica atribuida a factores como la discriminación laboral, la sobrecarga de trabajo doméstico no remunerado y la falta de redes de apoyo (Asobancaria, 2024). Esto también está relacionado con la variable `N_mujer` que proporciona información del número de mujeres en el hogar.

4. Conclusión

Este trabajo tuvo como objetivo construir un modelo predictivo de la pobreza a nivel hogar, abordándolo como un problema de clasificación. Para la selección de variables explicativas, se toma como referencia el índice de pobreza multidimensional, asegurando que las dimensiones clave de la pobreza que afectan a los hogares se reflejen adecuadamente en el modelo. Se utilizan diversos algoritmos de clasificación con el objetivo de predecir la probabilidad de que un hogar sea clasificado como pobre o no pobre, según si su ingreso per cápita o total se encuentra por debajo de la línea de pobreza establecida.

Los mejores modelos entrenados fueron aquellos que utilizaron métodos de ensamble, específicamente el boosting, un enfoque que construye modelos de aprendizaje supervisado fuertes combinando múltiples aprendices débiles. El método con mejor poder predictivo fue el que utilizó XGBoost frente a AdaBoost. A diferencia de AdaBoost, que ajusta los pesos de las observaciones mal clasificadas en cada iteración utilizando una función de pérdida exponencial, XGBoost ajusta el modelo en función del gradiente de la función de pérdida. Esto le permitió manejar de manera más efectiva y flexible problemas complejos, como la predicción de la pobreza.

Los modelos fueron especificados utilizando distintas combinaciones y transformaciones de las variables descritas en la sección de Datos. Sin embargo, el mejor desempeño se obtuvo con el modelo que incluyó variables asociadas al jefe del hogar, tales como el sexo, la edad, la ocupación y, especialmente, su afiliación al sistema de salud, destacándose la pertenencia al régimen subsidiado como una de las variables más relevantes según la importancia relativa en XGBoost. También resultaron significativas diversas características del hogar, como el número de mujeres, la proporción de menores de 12 años (en lugar de menores de 6, que fue menos informativa en modelos con menor desempeño), y los niveles educativos alcanzados por los miembros del hogar, donde tener al menos un integrante con educación universitaria se asoció fuertemente con la variable objetivo.

Adicionalmente, variables relacionadas con condiciones habitacionales (como el hacinamiento o la tenencia de vivienda) y la localización del hogar dentro de un área metropolitana también aportaron al poder predictivo del modelo. Finalmente, el balanceo de clases mejoró significativamente la capacidad del modelo para discriminar entre categorías, lo que se tradujo en un mejor desempeño general. Con miras a mejorar los resultados, incorporar indicadores relacionados con la salud y la nutrición infantil, así como características físicas de la vivienda —como el material de pisos y paredes, y la disponibilidad de bienes durables o activos del hogar—, podría contribuir al poder predictivo del modelo. Asimismo, incluir información sobre la participación en programas de transferencias o subsidios estatales permitiría capturar mejor el grado de vulnerabilidad económica. Además, el uso de redes neuronales podría ser una gran herramienta para mejorar el poder predictivo del modelo

Referencias

- Asobancaria (2024). Jefatura femenina en colombia. <https://www.asobancaria.com/wp-content/uploads/2024/04/1411-BE.pdf>.
- Baker, E. and Bentley, R. (2011). Housing and poverty: A critical review of the literature. *Urban Studies Review*, 48(8):1619–1638.
- Cancian, M. and Haskins, R. (2014). Changes in family composition: Implications for income, poverty, and public policy. *The ANNALS of the American Academy of Political and Social Science*, 654(1):31–47.
- DANE (2012). Algoritmo para la construcción del Índice de pobreza multidimensional (ipm). https://www.dane.gov.co/files/operaciones/PM/Algoritmo_para_la_construccion_del_indice_de_pobreza.pdf. Bogotá, Colombia.
- DANE) (2014). Metodología: Índice de pobreza multidimensional (ipm). <https://www.dane.gov.co/files/operaciones/PM/met-IPM.pdf>. Bogotá, Colombia.
- Departamento Administrativo Nacional de Estadística (DANE) (2017). Medición de Pobreza Monetaria - Misión para el Empalme de las Series de Empleo, Pobreza y Desigualdad 2002-2010. Consultado el 13 de abril de 2025.
- Departamento Nacional de Planeación (2012). Pobreza monetaria y desigualdad del ingreso: Análisis de los resultados recientes 2010-2011. Bogotá, Colombia.
- Grossbard, S. (2006). *Jacob Mincer: A Pioneer of Modern Labor Economics*. Springer Science+Business Media, Inc., New York.
- INEI (1999). La educación y el círculo vicioso de la pobreza. <https://proyectos.inei.gob.pe/web/biblioineipub/bancopub/Est/Lib0079/cap10.HTM>. Lima, Perú.
- Lorentzen, J. C., Johanson, G., Björk, F., and Stensson, S. (2022). Overcrowding and hazardous dwelling condition characteristics: A systematic search and scoping review of relevance for health. *International Journal of Environmental Research and Public Health*, 19(23). Disponible en <https://www.mdpi.com/1660-4601/19/23/15542>.
- MacDonald, J. (2004). Vivienda y pobreza: una relación compleja. *Revista Cuadernos de Vivienda y Urbanismo*.
- Maris, L. (2023). Agua segura y saneamiento para una vida sana. impacto caf. Disponible en <https://www.caf.com/media/4663661/impacto-caf-agua-y-saneamiento-informe-completo.pdf>.
- Meng, X., Gregory, R., and Wan, G. (2007). Urban poverty in china and its contributing factors, 1986–2000. *Review of Income and Wealth*, 53(1):167–189.
- Mok, T. Y., Gan, C., and Sanyal, A. (2007). The determinants of urban household poverty in malaysia. *Journal of Social Sciences*, 3(4):190–196.
- Naus (2025). uniandes-bdml-202510-ps2. <https://kaggle.com/competitions/uniandes-bdml-202510-ps-2>. Kaggle.

- Núñez, J. (2023). Logros en equidad del sistema de salud y la reforma en colombia. Informe desarrollado por Fedesarrollo, con acceso a través de su repositorio. Teléfono: (601) 3259777.
- Observatorio del Hábitat (2020). Relación entre la pobreza monetaria y el gasto en vivienda. <https://observatoriohabitat.org/wp-content/uploads/2022/06/2020-12-10-Documento-POBREZA-INDUCIDA-POR-HABITAT-O-VIVIENDA.pdf>. Documento de trabajo.
- ONU Mujeres Colombia and DANE (2020). Tiempo de cuidados: las cifras de la desigualdad. <https://colombia.unwomen.org/es/biblioteca/publicaciones/2020/01/tiempo-de-cuidados-las-cifras-de-la-desigualdad>.
- Paniagua, C. (2023). Electrificación para un desarrollo sostenible. impacto caf. Disponible en <https://www.caf.com/media/4670365/impactocaf-electrificacion-sostenible-informe-completo.pdf>.
- Polin, V. and Raitano, M. (2014). Poverty transitions and trigger events across eu groups of countries: Evidence from eu-silc. *Journal of Social Policy*, 43(4):745–772.
- Sen, A. (1999). *Development as Freedom. Capítulo 4: La pobreza como privación de capacidades*. Alfred A. Knopf, Inc., New York. Publicado en español por Editorial Planeta, S.A., 2000.
- Sikander, M. U. and Ahmed, M. (2008). Household determinants of poverty in punjab: A logistic regression analysis of mics (2003-04) data set. In *8th Global Conference on Business & Economics*, pages 1–41, Florence, Italy.
- Terry, G. (2004). Poverty reduction and violence against women: Exploring links, assesing impact. *Development in Practice*, 14(4):469–480.
- UN Women (2015). Monitoring gender equality and the empowerment of women and girls in the 2030 agenda for sustainable development. New York.
- United Nations Development Programme and Oxford Poverty and Human Development Initiative (2024). Global multidimensional poverty index report 2024. Disponible en: <https://ophi.org.uk/event/launch-2024-global-multidimensional-poverty-index-report>.
- Widyanti, W., Suryahadi, A., Sumarto, S., and Yumna, A. (2010). The relationship between chronic poverty and household dynamics: Evidence from indonesia. *SSRN Electronic Journal*. Accessed via SSRN.

5. Apéndice

Cuadro 3. Distribución porcentual por dominio según condición de pobreza y total - Bases train y test

Variable	Base <i>train</i>		Base <i>test</i>	
	Pobre	No pobre	Total	Total
ARMENIA	2.60	3.50	3.40	3.60
BARRANQUILLA	3.10	4.20	4.00	4.30
BUCARAMANGA	1.90	3.50	3.20	3.30
CALI	2.40	4.50	4.00	4.20
CARTAGENA	3.10	3.30	3.20	3.40
CUCUTA	3.90	2.60	2.80	3.10
FLORENCIA	4.00	2.70	3.00	3.10
IBAGUE	2.10	3.50	3.20	3.40
MANIZALES	1.50	4.20	3.70	3.90
MEDELLIN	3.00	6.00	5.40	5.80
MONTERIA	3.20	3.00	3.00	3.10
NEIVA	3.00	3.50	3.40	3.70
PASTO	3.00	3.00	3.00	3.30
PEREIRA	1.50	3.80	3.40	3.70
POPAYAN	4.30	3.40	3.60	3.80
QUIBDO	4.00	2.10	2.50	2.60
RESTO URBANO	15.20	9.10	10.30	11.10
RIOHACHA	5.30	2.80	3.30	3.60
RURAL	14.10	8.20	9.40	10.10
SANTA MARTA	4.10	3.40	3.60	3.90
SINCELEJO	3.50	3.20	3.20	3.50
TUNJA	1.90	3.00	2.80	2.90
VALLEDUPAR	4.10	2.80	3.00	3.20
VILLAVICENCIO	2.10	3.50	3.20	3.50

Nota: la tabla fue realizada con la muestra *train* (Obs. 164.960), los resultados en términos de distribución son iguales para la muestra *train* con la muestra balanceada *upsampling* (Obs. 263.872)

Fuente: Elaboración propia. Naus (2025) con base en GEIH y MESEP (s.f.)


Cuadro 4. Resultados generales modelos logit

Modelo	parameter	Accuracy	Kappa	AccuracySD	KappaSD	No. Predictores	F1 (privado) - Kaggle
Logit 1	NA	0.77	0.54	0.00	0.00	12	
Logit 2	NA	0.77	0.54	0.00	0.01	11	
Logit 3	NA	0.77	0.54	0.00	0.01	12	
Logit 4	NA	0.79	0.58	0.00	0.00	13	0.6050
Logit 5	NA	0.79	0.58	0.00	0.00	14	
Logit 6	NA	0.79	0.59	0.00	0.00	13	0.6048

Nota: *Accuracy* es la proporción de predicciones correctas realizadas por el modelo, calculada como el número de predicciones correctas dividido por el total de observaciones. *Kappa* es una métrica que mide la concordancia entre las predicciones del modelo y las verdaderas etiquetas, ajustada por el azar. Un valor de Kappa cercano a 1 indica una alta concordancia, mientras que valores cercanos a 0 sugieren una concordancia similar al azar. Los predictores utilizados en los modelos Logit incluyen número de dependientes, nivel educativo del jefe de hogar, hacinamiento, sexo, cotización a pensión y régimen de salud del jefe del hogar, número de mujeres en el hogar, proporción de ocupados en el hogar, clase (cabecera o resto) e interacciones entre algunas variables.


Fuente: Elaboración propia. Naus (2025) con base en GEIH y MESEP (s.f.)

Figura 2. Importancia de las variables del mejor modelo estimado usando XGBoost



Nota: Importancia de las variables obtenidas usando el código `varImp(Xgboost_tree)` en R, luego de la calibración del modelo con el que se obtuvo el mejor F1.

Figura 3. Resultados de validación cruzada para selección de hiperparámetros



Nota: Resultados de F1 obtenidos mediante validación cruzada para distintos valores de λ y α a través de 4 modelos. El Modelo 1 incluye 8 variables explicativas, el Modelo 2 incluye 12, el Modelo 3 incluye 13 y el Modelo 4 incluye 11 (de izquierda a derecha). Para facilitar la visualización de los hiperparámetros seleccionados, las figuras se restringieron a los siguientes valores máximos de λ : $\lambda \leq 0,005, 0,05, 0,05$ y $0,1$, respectivamente.

Modelo de entrenamiento	Hiperparámetros luego de cross validation	Variables usadas y diferencias	F1 (Kaggle - Public scores)	Nombre de los archivos en GitHub
XGBoost 4 (final)	rounds = 500 (Número de rondas (iteraciones)) max_depth = 7 (Profundidad máxima del árbol) eta = 0.05 (Tasa de aprendizaje) gamma = 0 (Penalización por complejidad) min_child_weight = 5 (Peso mínimo de un nodo hijo) colsample_bytree = 0.6 (Fracción de características por árbol) subsample = 0.7 (Fracción de muestras para cada árbol) method = cv (cross-validation) number = 5 (Número de particiones (folds) para la validación cruzada) sampling = smote (Sobremuestreo de la clase minoritaria (Pobre))	jefe.edad + jefe.mujer + jefe.edad2 + jefe.salud_sub + N_personas + hacinamiento + max_nivel_educ + Clase + pago.arriendo + viv.noPropia + lp + prop.fuentes_ing + prop.ina.pet + Dominio + prop.ocu.pet + jefe.pension + prop.menores12.pob + prop.mayores.pob + prop.anios_educ + tipo.trabajo + prop.des.pet + jefe.ocu + N_mujer	0.6962	3.7_model_XGBoost_4.Final.R
	method = xgbTree (método XGBoost con árboles de decisión) metric = F1 (métrica a optimizar)	1) Respecto al XGBoost final no se incluyen las variables de pago.arriendo, prop.des.pet, jefe.ocu y N_mujer. 2) Se usa la variable de proporción de menores de 6 años (prop.menores.pob) en lugar de la proporción de 12 años (prop.menores12.pob). 3) Se usa la variable del promedio de años de educación de las personas de 15 años y más en el hogar (promedio_anios_educ) en lugar de la proporción de años de educación de todos los integrantes del hogar (prop.mayores.pob).	0.6907	3.7_model_XGBoost_3.R
	rounds = 250 max_depth = 7 eta = 0.05 gamma = 0.1 min_child_weight = 1 colsample_bytree = 0.8 subsample = 0.7 method = cv number = 5 sampling = smote	Respecto al XGBoost 3 no se incluyen las variables prop.anios_educ + tipo.trabajo + prop.des.pet + jefe.ocu + N_mujer.	0.6743	3.7_model_XGBoost_2.R
	method = xgbTree metric = F1	Respecto al XGBoost 2 se incluyeron los siguientes cambios: 1) La métrica a optimizar usada es ROC y no F1 como en el resto de XGBoost. 2) No se realiza ningún sobremuestreo de la clase minoritaria (Pobre). 3) No se incluyen las variables lp, prop.fuentes_ing, prop.ina.pet, Dominio, prop.ocu.pet, jefe.pension, prop.menores.pob, prop.mayores.pob	0.6339	3.7_model_XGBoost_1.R
AdaBoost 2	method = cv (cross-validation) number = 5 (Número de particiones (folds) para la validación cruzada)			
	mfinal = 500 (número iteraciones) maxdepth = 3 (Profundidad de los árboles) coefficient = Freund (Método pesos clasificadores)	1) Respecto al XGBoost final no se incluyen las variables de pago.arriendo, prop.des.pet, jefe.ocu, N_mujer y dominio. El modelo es similar al XGBoost 3.	0.6492	3.4_model_boosting_ajustado.R
AdaBoost 1	method = AdaBoost.M1 (Algoritmo a usar) metric = ROC (métrica a optimizar)			
	method = cv number = 5 mfinal = 500 maxdepth = 5 coefficient = Freund	Respecto al AdaBoost 2 se utilizan las siguientes variables: hacinamiento, Clase, jefe.mujer.f, N_ocupados, jefe_mayor.f, jefe_nivel_educ, Mayor.dependiente.f, prop.ocu.pet.f, jefe.cot.pens, N_menores.f, jefe.cont.salud, viv.noPropia, N_desocupados.f	0.6099	3.4_model_boostingB.R